Previsão de Demanda de E-commerce

Estudo de Caso 2- MS715

Gabriel Augusto Rebouças
IMECC/UNICAMP
g239480@dac.unicamp.br

Letícia Palomero
IMECC/UNICAMP
l239038@dac.unicamp

Lucas dos Santos
IMECC/UNICAMP
l252789@dac.unicamp.br

***Abstract*—Este trabalho apresenta um estudo de caso de previsão de demanda de um e-commerce brasileiro a partir do histórico de vendas da Olist, entre janeiro de 2017 e agosto de 2018. Foram construídas séries semanais de itens vendidos para as 16 categorias de maior volume, que somam ao menos 80% dos itens, e para a série agregada. Dois modelos foram comparados: a regressão linear e o ARIMA. As previsões foram confrontadas com os dados reais em uma janela de teste de 12 semanas, e os pressupostos de cada modelo foram verificados por testes estatísticos. Nenhuma categoria cumpriu os três pressupostos da regressão, sendo a autocorrelação dos resíduos a violação mais frequente. Com apenas 86 semanas de dados, não foi possível estimar a sazonalidade, e nenhum dos modelos se mostrou efetivamente adequado para uso operacional.**

***Index Terms*—E-commerce, Série Temporal, Regressão Linear, ARRIMA.**

I. Introdução

O comércio eletrônico (*e-commerce*) consolidou-se na atualidade como uma das indústrias que mais crescem no varejo brasileiro. Impulsionado pela digitalização, pela universalização da internet e pela popularização dos *smartphones*, o setor já apresentava uma expansão significativa antes do ano de 2020, com um faturamento anual de R$90 bilhões [1]. A pandemia de Covid-19, porém, teve uma grande influência no desenvolvimento expressivo da área, uma vez que as condições do período forçaram a abertura de milhares de lojas virtuais, a migração dos usuários ao ambiente digital e a mudança do comportamento e das preferências do consumidor. O setor continuou desenvolvendo-se ao longo dos anos demonstrando um crescimento médio anual de 17% no período de 2019 a 2024, além de um faturamento anual de R$235.5bi no ano de 2025 . [1].

Entretanto, a expansão do setor trouxe uma maior competitividade entre empresas e comerciantes, além de elevar a expectativa do consumidor quanto à disponibilidade, ao frete, ao prazo, ao preço e à confiabilidade do produto. Nessa perspectiva, com a alta concorrência, o prazo de entrega se tornou um fator decisivo na fidelização do cliente. Como consequência, o planejamento de demanda e de estoque passou a ser essencial para competitividade de um mercado digital.

A previsão de demanda no varejo é tradicionalmente abordada na literatura por meio de modelos de séries temporais, como a regressão linear,o modelo de ARIMA [5] e, mais recentemente, os métodos de aprendizado de máquina. Entretanto, poucos estudos tratam da previsão de categoria com séries curtas, uma vez que a falta de dados prejudica o treinamento e verificação dos resultados obtidos.

Nessa perspectiva, o presente trabalho tem como objetivo comparar dois métodos de previsão de demanda, mais especificamente, o método de regressão linear e o método ARIMA, a partir do histórico de vendas de um e-commerce brasileiro no período de 2017 a 2018. Tal comparação considera o comportamento das previsões em uma janela de 12 semanas para as séries temporais observadas referentes a cada categoria de produtos.

II. Dados

Para a análise, foram utilizados dados reais e anonimizados de pedidos realizados na plataforma da Olist [2], empresa brasileira de comércio eletrônico, entre 2017 e 2018. A base reúne mais de 100 mil pedidos e contempla informações sobre os produtos (categoria, dimensões, peso e preço), os vendedores e os clientes, além dos dados de cada pedido.

Devido à grande quantidade de produtos e pedidos, o processamento da base foi realizado por meio de consultas SQL, executadas em Julia com a biblioteca DuckDB [3]. As 74 categorias originais foram ordenadas de forma decrescente pelo número de itens vendidos no período analisado, e foram selecionadas as categorias necessárias para que, em conjunto, representassem ao menos 80% do total de itens vendidos. Esse critério resultou em 16 categorias. A seleção teve como objetivo permitir uma análise mais estruturada e aprofundada de cada grupo de produtos, evitar séries muito esparsas e considerar as diferenças de escala de vendas e de sazonalidade entre os conjuntos.

A remoção das categorias não selecionadas implicou, necessariamente, uma modificação nos pedidos da base. Pedidos compostos exclusivamente por itens das categorias removidas foram excluídos por completo. Já nos pedidos que continham itens tanto de categorias selecionadas quanto de categorias removidas, apenas os itens removidos foram descartados, e o valor total do pedido foi reduzido de acordo com o preço desses itens.

Para cada categoria selecionada, construiu-se uma série temporal de itens vendidos. Além disso, foi utilizada uma série agregada, construída a partir da base filtrada, totalizando 17 séries analisadas.

A. *Análise descritiva*

A Figura 1 mostra quanto cada categoria representa do total de itens vendidos. As vendas estão bem distribuídas, sem uma categoria dominante: a maior, cama_mesa_banho, tem cerca de 12% do total, seguida por beleza_saude (10,6%) e esporte_lazer (9,5%). Essas três mais moveis_decoracao, informatica_acessorios, utilidades_domesticas e relogios_presentes somam cerca de 64% dos itens vendidos. As outras nove categorias ficam entre 2,8% e 5%, sendo papelaria (2,8%), eletronicos (3%) e bebes (3,4%) as menores.

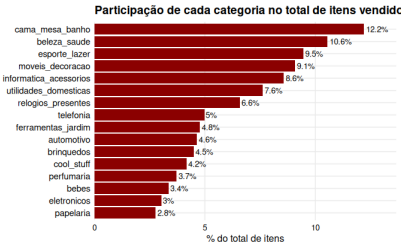


Fig. 1: Participação de cada categoria no total de itens vendidos

A Figura 2 mostra o total de itens vendidos por mês. Em 2017 as vendas crescem de cerca de 1000 itens em janeiro para aproximadamente 4800 em outubro, com oscilações em alguns meses, como a queda de junho. Novembro de 2017 chega a cerca de 7300 itens, por causa da Black Friday, e dezembro cai para perto de 4600. A partir de 2018 o patamar fica mais alto, entre 5400 e 7500 itens por mês, com picos em janeiro e abril, ambos em torno de 7500. Por isso o pico de novembro não destoa tanto no gráfico mensal, já que ele se concentra em uma única semana. A última barra, de agosto de 2018, é menor porque a base tem apenas três semanas desse mês.

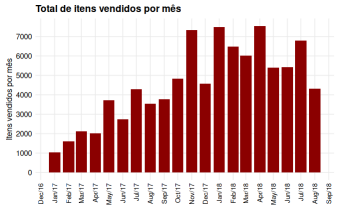


Fig. 2: Total de itens vendidos por mês

III. Modelos Aplicados e Analisados

Para desenvolvimento da previsão de demanda, foram analisados dois modelos diferentes, sendo eles a Regressão Linear e o modelo de ARIMA. Ambos foram aplicados ao período de 02/01/2017 a 20/08/2018 e sua eficácia foi comparada a partir de testes estatísticos.

A. *Regressão Linear*

O primeiro modelo utilizado foi a regressão linear para series temporais [5], a qual supõe que a demanda y_t no instante t pode ser decomposta em uma parte sistemática, linear nos parâmetros, e um erro aleatório: $y_t = \beta_0 + \beta_1 t + \varepsilon_t$. No modelo total, obtivemos um intervalo de confiança para os produtos a serem vendidos de, (IC 95%: 12,8 a 18,5) e $R^2 = 0{,}59$, o que é um modelo aceitável, devido a falta de dados, discutidas mais a frente.

B. *ARIMA*

O segundo modelo é o ARIMA(p, d, q) [5], em que p é o número de valores passados da série (em semanas) incluídos no modelo, d é o número de diferenciações aplicadas e q é o número de erros passados incluídos. Os três parâmetros foram escolhidos com a função `auto.arima` do pacote `forecast` do R [4], com base no procedimento de ajuste de modelos ARIMA descrito em [5]. Optou-se pelo ARIMA em vez do SARIMA uma vez que a quantidade de dados disponível é insuficiente para que o modelo identifique a sazonalidade. Para a série total, o modelo final obtido foi o ARIMA$(2, 1, 2)$.

IV. Requisitos dos Modelos

A Regressão linear como o modelo ARIMA possuem resultados confiáveis se alguns requisitos forem cumpridos, sendo eles para o de regressão: Independência dos resíduos, Homocedasticidade e normalidade dos resíduos. Testamos isso com Durbin-Watson [6], Breusch-Pagan [7] e Shapiro-Wilk [8], já o modelo ARIMA pede uma série estacionária, o qual foi feito atráves do teste ADF [9]. A Tabela I traz os resultados para cada teste em cada categoria.

TABLE I: Resultados dos testes de diagnóstico por categoria (A = Aprovado, P = Reprovado).

Categoria	Resíduos normais	Variância constante	Resíduos independentes	Série estacionária	Resíduos normais do ARIMA
geral	P	A	P	P	P
automotivo	A	P	P	A	P
bebes	A	P	P	A	A
beleza_saude	P	P	P	A	P
brinquedos	P	A	P	P	P
cama_mesa_banho	P	A	P	P	P
cool_stuff	A	A	P	P	A
eletronicos	P	P	P	P	P
esporte_lazer	A	P	P	P	P
ferramentas_jardim	P	A	P	P	P
informatica_acessorios	P	P	P	P	P
moveis_decoracao	P	A	P	P	P
papelaria	P	A	P	P	P
perfumaria	P	A	P	P	P
relogios_presentes	P	P	P	P	P
telefonia	P	A	P	P	P
utilidades_domesticas	A	P	P	A	P

Sem contar o modelo geral, a normalidade dos resíduos da regressão falhou em 11 das 16 categorias, a variância constante em 8 e a independência em todas as 16. Nenhuma categoria cumpre os três requisitos, sendo o pior a autocorrelação. A respeito do ARIMA o ADF só indicou estacionariedade em 4 categorias, a normalidade dos resíduos do ARIMA falhou em 14 das 16 categorias.

A. *Diagnóstico da regressão no modelo geral*

No QQ-Plot a figura 3 os residuos do modelo acompanham quase que perfeitamente a reta no centro, porém nas extremidades há um desvio evidente de ambos os lados, podendo indicar uma normalidade onde se há caudas pesadas, uma transformação dos dados foi considerada para avaliar

a normalidade, porém isso foi postergado para o estudo de caso 3, sendo assim, o teste de Shapiro-Wilk considerou os dados como não normais, além do mais a figura 4 nos permite enxergar comportamentos dos resíduos seguem concentrados, porém em alguns momenentos, possuem grande dispersões. Com isso, o teste de homocedasticidade falhou, indicando heterocedásticidade, com isso, podemos concluir que há presença de requisitos fundamentais para a regressão foi violada, sendo assim, o uso deste modelo geral para a previsão de uma nova demanda, não se encaixa adequadamente com os dados obtidos.

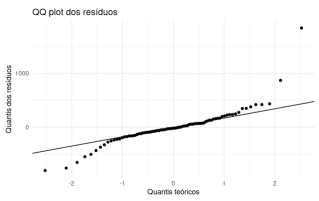


Fig. 3: qq-plot para a distribuição normal do modelo geral

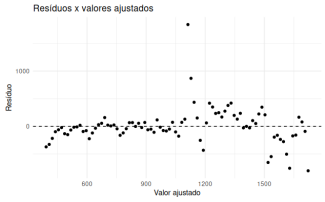


Fig. 4: Teste de Homocedasticidade

B. Diagnóstico do modelo ARIMA

Como visto na tabela I, a estacionaridade da série é reprovada em quase todas as categorias juntamente com a normalidade dos resíduos, exceto na categoria de bebes, indicando assim que o modelo não é o ideal para estas categorias.

V. Resultados

A. Comportamento da série

A Figura 5 mostra os itens vendidos por semana no total. Ao longo de 2017 as vendas crescem de forma quase contínua, saindo de poucas dezenas de itens em janeiro para cerca de 1000 por semana em outubro. O maior valor da série, de aproximadamente 2900 itens, ocorre na última semana de novembro de 2017, que coincide com a Black Friday, e logo depois as vendas caem para menos de 800 itens em dezembro.

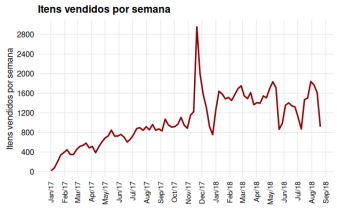


Fig. 5: série temporal dos pedidos

B. Teste de modelo nas últimas 12 semanas

Para comparar os modelos, separamos as últimas 12 semanas da base, equivalente aos meses de junho a agosto de 2018 para a validação dos modelos, este treinamento foi feito com 52 semanas anteriores. A figura 6 mostra a diferença entre o modelo ARIMA e o de regressão com o valor real da série. A regressão fica acima do valor real em basicamente toda a série, já o modelo ARIMA segue quase que um comportamento linear, mas sempre chutando na média da série, comportamento esse que vai se estender para os modelos vistos por categorias.

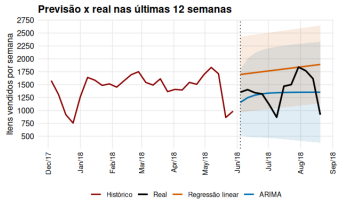


Fig. 6: Comparação do modelo geral com os resultados obtidos

C. Previsão de modelos por categorias

Para quase todas as séries, temos um comportamento similar para os modelos, onde a regressão chuta sempre valores acima do observado já o modelo ARIMA, tenta se adequar mais ao padrão da série, sendo possível observar que ela não segue um comportamento fixo como acontece na regressão, entretando, como no modelo geral, o ARIMA, sempre chuta valores na média da série, sendo uma alternativa boa, já que se há poucos dados.

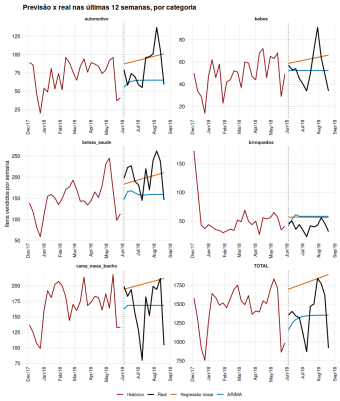


Fig. 7: Comparação do modelo geral com os resultados obtidos por categoria

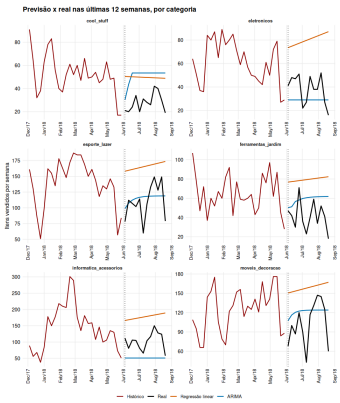


Fig. 8: Comparação do modelo geral com os resultados obtidos por categoria



Fig. 9: Comparação do modelo geral com os resultados obtidos por categoria

D. Previsão das próximas 12 semanas

Após o teste, os modelos foram ajustados para toda a base, a fim de fazer uma previsão de demanda para as próximas 12 semanas, isso é, 3 meses. Para o modelo total, observa-se a mesma tendência de ambos os modelos quando foi-se realizada os testes, há regressão ainda permanece com valores altos enquanto que o modelo ARIMA tentou se adaptar a toda a série.

E. Previsão das próximas 12 semanas por categoria

O mesmo foi feito para a previsão de demanda no mesmo periódo, porém agora, separado por categorias. Os dois modelos ficam próximos em bebes, perfumaria e beleza e saude, onde o ARIMA oscila em torno da reta da regressão. Em outras categorias a diferença é grande, como em eletronicos, em que a regressão prevê cerca de 62 a 69 itens contra cerca de 29 do ARIMA, e em ferramentas e jardim, informatica e acessorios e cool stuff. Em todas as categorias o pico de novembro de 2017 aparece no histórico, mas nenhum modelo reproduz um pico parecido, o que é esperado, já que não foi possível incluir sazonalidade com menos de dois anos de dados

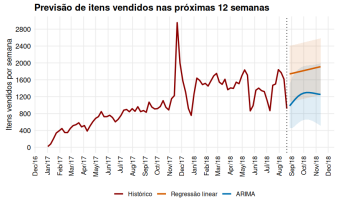


Fig. 10: Comparação de modelos para a previsão dos proxímos 3 meses

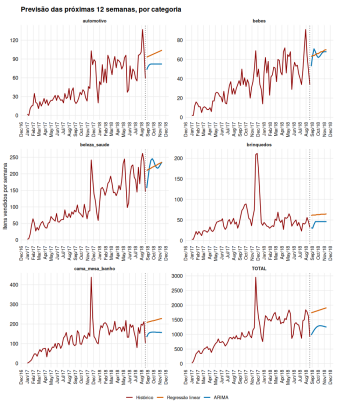


Fig. 11: Previsão por categoria dos próximos 3 meses

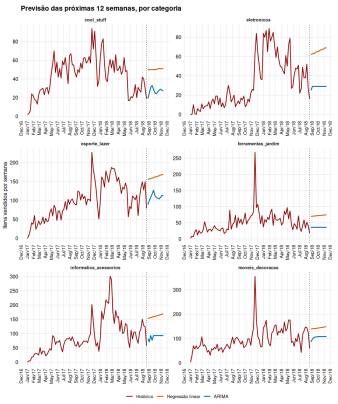


Fig. 12: Previsão por categoria dos próximos 3 meses

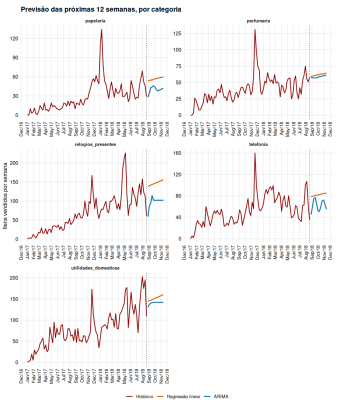


Fig. 13: Previsão por categoria dos próximos 3 meses

A Tabela II traz os valores previstos para o total nas próximas 12 semanas, com a faixa de 95% de cada modelo. A regressão linear prevê um crescimento constante, de 1739 para 1911 itens por semana, enquanto o ARIMA parte de 982, sobe até cerca de 1300 em outubro e volta para 1252 em novembro. A diferença entre os modelos é de 757 itens na primeira semana e de 659 na última. Note que os modelos se diferenciam e muito nos valores previstos, onde a regressão nos dá valores muito acima comparado com o ARIMA.

TABLE II: Previsão do total de itens vendidos nas próximas 12 semanas, com uma faixa de 95%.

	Regressão linear			ARIMA		
Semana	**Previsto**	**Inferior**	**Superior**	**Previsto**	**Inferior**	**Superior**
27/08	1739	1075	2403	982	463	1501
03/09	1754	1090	2419	1063	456	1671
10/09	1770	1105	2435	1142	512	1772
17/09	1786	1120	2451	1209	574	1843
24/09	1801	1135	2468	1256	621	1892
01/10	1817	1150	2484	1285	649	1922
08/10	1833	1165	2500	1298	659	1936
15/10	1848	1180	2516	1297	652	1943
22/10	1864	1196	2533	1289	630	1948
29/10	1880	1211	2549	1277	596	1957
05/11	1895	1226	2565	1263	555	1972
12/11	1911	1241	2581	1252	511	1992

VI. Limitações e próximos passos

A partir das análises feitas conclui-se que, com esses dados, os modelos observados não servem para uso real. Como são apenas 86 semanas consideradas, não há como estimar sazonalidade, como podemos ver no período de Novembro a Dezembro essa faixa de tempo vira outlier e distorce os resíduos, QQ plot e a reta. Os requisitos da regressão falharam em praticamente todas as categorias, e os resíduos do ARIMA não são normais, o que prejudica os intervalos de previsão. Várias categorias vendem poucas unidades por semana,entre 20 a 60. Além disso, usamos uma única janela de teste e avaliação visual.

Para dar continuidade ao trabalho espera-se a realização de transformações nas variáveis a fim de verificar se assim os requisitos seriam cumpridos, além do mais o uso de modelos não paramétricos assim como também reduzir a quantidade de categorias através de grupos. Contudo a principal limitação é com respeito a quantidade de dados, tendo uma serie temporal de apenas um ponto quando visto de modo anual.

References

[1] ABComm, "Dados do comércio eletrônico," 2026. [Online]. Available: https://dados.abcomm.org/. [Accessed: Oct. 18, 2026].

[2] Olist, "Brazilian e-commerce public dataset by Olist," Kaggle, 2018. [Online]. Available: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce. [Accessed: Oct. 18, 2026].

[3] M. Raasveldt and H. Mühleisen, "DuckDB: an Embeddable Analytical Database," in *Proceedings of the 2019 International Conference on Management of Data (SIGMOD '19)*, ACM, 2019, pp. 1981–1984. doi: 10.1145/3299869.3320212.

[4] R. J. Hyndman and Y. Khandakar, "Automatic time series forecasting: The forecast package for R," *Journal of Statistical Software*, vol. 27, no. 3, pp. 1–22, 2008. doi: 10.18637/jss.v027.i03.

[5] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021. [Online]. Available: https://otexts.com/fpp3/. [Accessed: Oct. 23, 2026].

[6] J. Durbin and G. S. Watson, "Testing for serial correlation in least squares regression: I," *Biometrika*, vol. 37, no. 3/4, pp. 409–428, 1950.

[7] T. S. Breusch and A. R. Pagan, "A simple test for heteroscedasticity and random coefficient variation," *Econometrica*, vol. 47, no. 5, pp. 1287–1294, 1979.

[8] S. S. Shapiro and M. B. Wilk, "An analysis of variance test for normality (complete samples)," *Biometrika*, vol. 52, no. 3/4, pp. 591–611, 1965. doi: 10.1093/biomet/52.3-4.591.

[9] D. A. Dickey and W. A. Fuller, "Distribution of the estimators for autoregressive time series with a unit root," *Journal of the American Statistical Association*, vol. 74, no. 366, pp. 427–431, 1979. doi: 10.2307/2286348.